LAPORAN UTS PEMBELAJARAN MESIN

Eksperimen Komparasi Metrik Jarak pada Algoritma Clustering

Euclidean · Manhattan · Cosine × K-Means · DBSCAN · Hierarchical Clustering — terintegrasi dengan dataset proyek PBL kelompok

1. Identitas Laporan

Komponen	Isi
Judul	Eksperimen Komparasi Metrik Jarak pada Algoritma Clustering untuk Aplikasi Prediksi Estimasi Waktu Panen Selada
Kelompok	Kelompok 5
Anggota & peran	NAMA / NIM / PERAN Anselmus Marcel Putra Andria — 244107020141 — - Hierarchical Manhattan Dina Kumala Sari — 244107020072 — - K-Means Euclidean - K-Means Manhattan - Menentukan k M. Yahya Irvansyah — 244107020032 — - DBSCAN Cosine - Hierarchical Euclidean - Explore dataset Muhammad Pearl Ochada — 244107020064 — - DBSCAN Euclidean - DBSCAN Manhattan - Preprocessing Sharren Elvaretta Pratamadya Fianto — 244107020191 — - K-Means Cosine Similarity - Hierarchical Cosine
Mata kuliah / kelas	Pembelajaran Mesin / TI 3G / Teknik Informatika

2. Pendahuluan (± ½ halaman)

2.1 Latar Belakang Topik PBL

- Proyek PBL Kelompok 5 mengembangkan aplikasi mobile (Flutter + Flask REST API) untuk memprediksi estimasi waktu panen tanaman selada dari data pertumbuhan dan lingkungan (suhu, kelembapan, TDS, pH, dan hari tumbuh). Pada tahap eksplorasi, clustering dipakai untuk melihat apakah kondisi pertumbuhan membentuk kelompok alami.
- Euclidean, Manhattan, dan Cosine mendefinisikan "kedekatan" antar-data secara berbeda, sehingga bentuk dan kualitas cluster pada data selada ikut berubah. Eksperimen ini membandingkan ketiganya pada tiga algoritma clustering.

2.2 Tujuan Eksperimen

Membandingkan pengaruh tiga metrik jarak terhadap tiga pendekatan clustering, yaitu berbasis centroid (K-Means), berbasis kepadatan (DBSCAN), dan berbasis hierarki (Agglomerative Hierarchical Clustering), pada dataset PBL kelompok dan dataset kontrol.

2.3 Hipotesis (Prediksi Awal)

Kode	Pernyataan hipotesis
H1	Pada data berdimensi rendah dengan cluster bulat/konveks, K-Means dengan Euclidean memberikan pemisahan cluster terbaik.
H2	Pada data berbentuk non-konveks atau manifold kompleks, DBSCAN mengungguli K-Means, apa pun metrik jarak yang dipakai.
H3	Cosine mengungguli metrik lain pada data berdimensi tinggi yang lebih ditentukan oleh arah vektor daripada besarnya (mis. TF-IDF/embedding). Pada data berdimensi rendah, Cosine berisiko merusak struktur cluster asli.
H4	Dengan linkage yang sama, pergantian metrik jarak mengubah hasil Hierarchical Clustering lebih besar dibanding perubahan pada K-Means, karena metrik langsung menentukan urutan penggabungan cluster.
H5	Pada data sensor selada yang mengandung outlier, Manhattan lebih stabil dibanding Euclidean.

2.4 Karakteristik Data (wajib)

Karakteristik	Isi
Sumber data & cara pengumpulan	Dataset Kaggle "Lettuce Growth Days" (jurijsruko/lettuce); pengukuran harian per tanaman dari sensor lingkungan.
Jumlah sampel (baris)	3.169 baris (setelah pembersihan: 0 missing value, 0 duplikat)
Jumlah fitur (dimensi) setelah praproses	5 fitur numerik: Temperature (°C), Humidity (%), TDS Value (ppm), pH Level, Growth Days (Plant_ID, Date, dan kolom duplikat °F/Humidity pecahan tidak dipakai).
Tipe fitur (numerik/kategorikal/teks)	Seluruhnya numerik; tidak ada fitur kategorikal atau teks.
Label ground truth tersedia?	Tidak. Kolom ARI dan NMI diisi "–" untuk dataset PBL.
Perkiraan sebaran & outlier	Pemeriksaan IQR: tidak ada outlier pada kelima fitur (Temperature 18–33,5; Humidity 50–80; TDS 400–800; pH 6,0–6,8; Growth Days 1–48). Silhouette rendah (< 0,3) menandakan struktur cluster lemah dan sebaran kontinu.

3. Dasar Teori Singkat (± 1 halaman)

3.1 Metrik Jarak

Metrik	Rumus	Intuisi geometris
Euclidean (L2)	$d(x,y) = \sqrt{\Sigma\ (x_i - y_i)^2}$	Jarak garis lurus; sensitif terhadap skala dan outlier.

Metrik	Rumus	Intuisi geometris
Manhattan (L1)	$d(x,y) = \Sigma \lvert x_i - y_i \rvert$	Jarak menyusuri grid; lebih tahan terhadap outlier pada satu dimensi.
Cosine	$d(x,y) = 1 - (x \cdot y) / (\lVert x \rVert \lVert y \rVert)$	Selisih sudut antar-vektor; mengabaikan besar vektor. Rentang 0–2.

3.2 Algoritma Clustering

- **K-Means:** pembentukan centroid sebagai rata-rata anggota, minimisasi SSE (inertia), asumsi cluster konveks dengan ukuran serupa.
- **DBSCAN:** parameter eps dan min_samples; core point, border point, dan noise; mampu menemukan cluster berbentuk bebas.
- **Agglomerative Hierarchical Clustering:** penggabungan bertahap dari bawah ke atas; jenis linkage (single, complete, average, Ward); dendrogram dan cara memotongnya menjadi k cluster.

3.3 Matriks Kompatibilitas Algoritma × Metrik (scikit-learn)

Algoritma	Euclidean	Manhattan	Cosine
K-Means	Bawaan (KMeans)	Tidak didukung KMeans. Gunakan `KMedoids(metric='manhattan')` (scikit-learn-extra) atau K-Medians, dan sebutkan sebagai penyimpangan dari K-Means murni.	Normalisasi L2, lalu KMeans (spherical k-means).
DBSCAN	`metric='euclidean'`	`metric='manhattan'`	`metric='cosine'`, `algorithm='brute'`. Rentang jarak 0–2, eps wajib disetel ulang.
Hierarchical	`metric='euclidean'`; semua linkage, termasuk Ward	`metric='manhattan'`; linkage average/complete/single	`metric='cosine'`; linkage average/complete/single

4. Metodologi (± 1–1½ halaman)

4.1 Dataset

- **Dataset utama: data selada PBL (5 fitur numerik, k = 2), rinci di 2.4.**
- **Dataset kontrol: make_blobs (cluster bulat, k = 4) dan make_moons (non-konveks, k = 2) dengan random_state=42 dan jumlah sampel sesuai notebook template.**

4.2 Praproses

- Missing value diisi median (tidak ada yang ditemukan); duplikasi dicek (0). Outlier dicek dengan IQR dan tidak ditemukan, sehingga tidak ada baris yang dibuang.
- Tidak ada fitur kategorikal, sehingga tidak diperlukan encoding; ketiga metrik bermakna karena semua fitur numerik.

- StandardScaler untuk konfigurasi Euclidean dan Manhattan; Normalizer(norm='l2') untuk konfigurasi Cosine.
- DBI dan Silhouette dihitung tanpa titik noise

4.3 Penyetelan Parameter

Algoritma	Cara penyetelan
K-Means	k dipilih dengan Elbow dan Silhouette; pada data selada k = 2 dan dipakai juga untuk K-Medians dan spherical k-means. Dataset kontrol dikunci (Blobs = 4, Moons = 2).
DBSCAN	eps dari k-distance plot untuk tiap metrik; min_samples ≈ 2 × jumlah dimensi, minimal 4. Pada Blobs/Moons jumlah cluster hasil DBSCAN bebas (lihat kolom k).
Hierarchical	Average linkage untuk ketiga metrik; n_clusters sama dengan k pada K-Means.

4.4 Metrik Evaluasi

Kelompok	Metrik	Catatan penting
Internal	Silhouette Coefficient	Hitung dengan metrik yang sama dengan metrik clustering. Untuk DBSCAN, laporkan selalu berdampingan dengan % noise.
Internal	Davies-Bouldin Index (DBI)	Selalu dihitung dengan Euclidean, sehingga cenderung menguntungkan konfigurasi Euclidean. Gunakan sebagai pelengkap.
Eksternal (jika ada label)	ARI dan NMI	Acuan utama bila ground truth tersedia, termasuk pada dataset kontrol.
Khusus hierarchical	Cophenetic correlation	Seberapa baik dendrogram mempertahankan jarak asli, dihitung per metrik.
Operasional	Jumlah cluster, % noise, waktu eksekusi	Waktu dalam milidetik, rata-rata beberapa kali run bila memungkinkan.

4.5 Reproducibility

- `random_state=42` untuk semua proses acak.
- Python 3.13.16, numpy 2.1.3, pandas 2.2.3, scikit-learn 1.6.1, scipy 1.16.3; K-Means–Manhattan dijalankan sebagai K-Medians (implementasi sendiri).
- Titik noise DBSCAN dikeluarkan saat menghitung Silhouette dan DBI; persentasenya dilaporkan terpisah di kolom % noise.

5. Hasil (± 1–2 halaman)

5.1 Tabel Ringkasan Hasil

Algoritma	Metrik	k	% noise	Silhouette	DBI	ARI	NMI	Waktu (ms)
K-Means*	Euclidean	2	0.0	0.2085	1.9233	–	–	53.4
DBSCAN	Euclidean	2	0.9	0.2085	1.9138	–	–	102.1
Hierarchical	Euclidean	2	0.0	0.2085	1.9233	–	–	377.0
K-Means*	Manhattan	2	0.0	0.2558	1.9233	–	–	65.4

Algoritma	Metrik	k	% noise	Silhouette	DBI	ARI	NMI	Waktu (ms)
DBSCAN	Manhattan	2	0.9	0.1004	0.9931	–	–	98.6
Hierarchical	Manhattan	2	0.0	0.2554	1.9224	–	–	254.8
K-Means*	Cosine	2	0.0	0.2679	2.2656	–	–	30.4
DBSCAN	Cosine	2	0.3	0.2926	1.9607	–	–	113.3
Hierarchical	Cosine	2	0.0	0.2931	1.9598	–	–	282.2

** K-Means–Manhattan dijalankan dengan K-Medians; K-Means–Cosine dengan spherical k-means. ARI/NMI "–" karena data selada tidak berberlabel. Tabel 1: Lettuce (PBL).*

Tabel 2: Blobs (kontrol)

Algoritma	Metrik	k	% noise	Silhouette	DBI	ARI	NMI	Waktu (ms)
K-Means*	Euclidean	4	0.0	0.7979	0.2819	1.0	1.0	12.4
DBSCAN	Euclidean	7	9.0	0.6414	0.452	0.8412	0.8312	4.4
Hierarchical	Euclidean	4	0.0	0.7979	0.2819	1.0	1.0	9.5
K-Means*	Manhattan	4	0.0	0.79	0.2819	1.0	1.0	18.9
DBSCAN	Manhattan	7	8.2	0.6251	0.4567	0.8532	0.8397	4.6
Hierarchical	Manhattan	4	0.0	0.79	0.2819	1.0	1.0	5.6
K-Means*	Cosine	4	0.0	0.9699	0.1891	1.0	1.0	12.2
DBSCAN	Cosine	4	3.8	0.9774	0.1715	0.947	0.9267	6.7
Hierarchical	Cosine	4	0.0	0.9699	0.1891	1.0	1.0	9.4

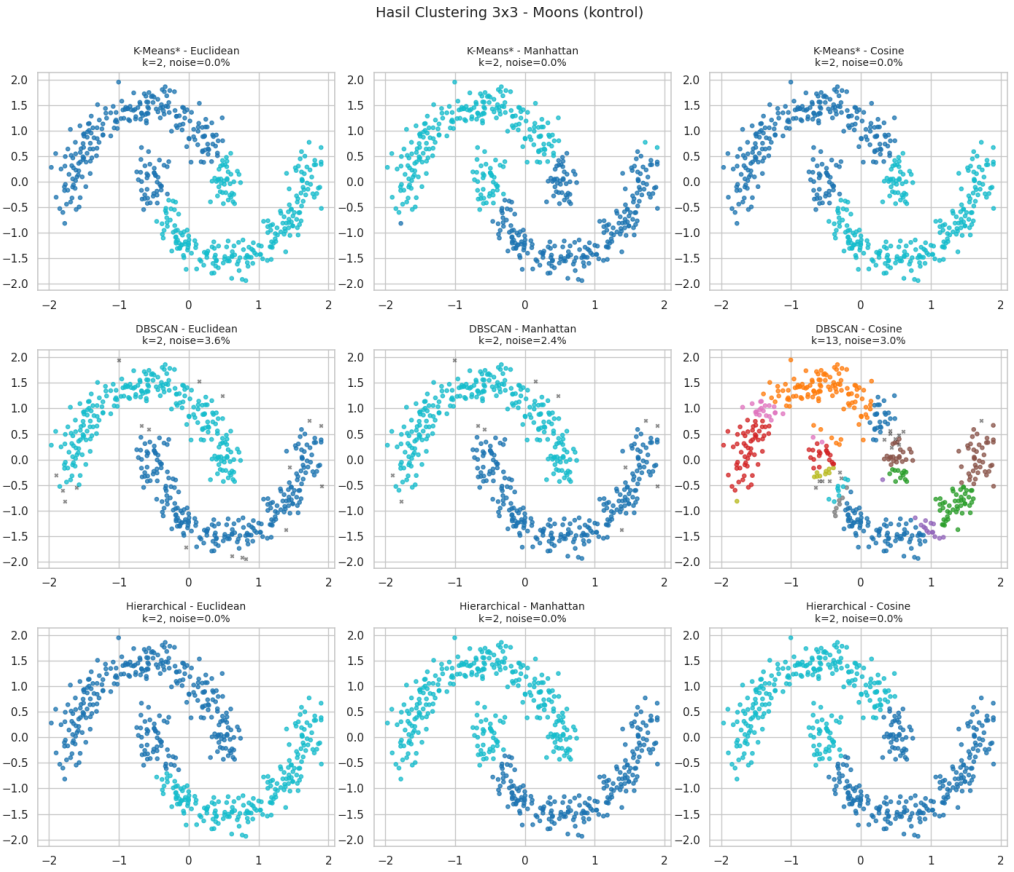
Tabel 3: Moons (kontrol)

Algoritma	Metrik	k	% noise	Silhouette	DBI	ARI	NMI	Waktu (ms)
K-Means*	Euclidean	2	0.0	0.49	0.8165	0.4451	0.3515	11.3
DBSCAN	Euclidean	2	3.6	0.3859	1.0109	0.9293	0.8825	4.5
Hierarchical	Euclidean	2	0.0	0.4563	0.8567	0.6329	0.6141	9.1
K-Means*	Manhattan	2	0.0	0.4839	0.8262	0.4292	0.3378	19.2
DBSCAN	Manhattan	2	2.4	0.3779	1.0094	0.9525	0.9129	5.1
Hierarchical	Manhattan	2	0.0	0.4484	0.8666	0.6916	0.6597	5.6
K-Means*	Cosine	2	0.0	0.7142	0.7757	0.4451	0.3515	11.8
DBSCAN	Cosine	13	3.0	0.3418	0.4443	0.17	0.2613	6.4
Hierarchical	Cosine	2	0.0	0.7105	0.7801	0.4239	0.3332	9.4

5.2 Visualisasi Hasil Clustering



- *Gambar 1: Grid clustering Lettuce (PBL).*

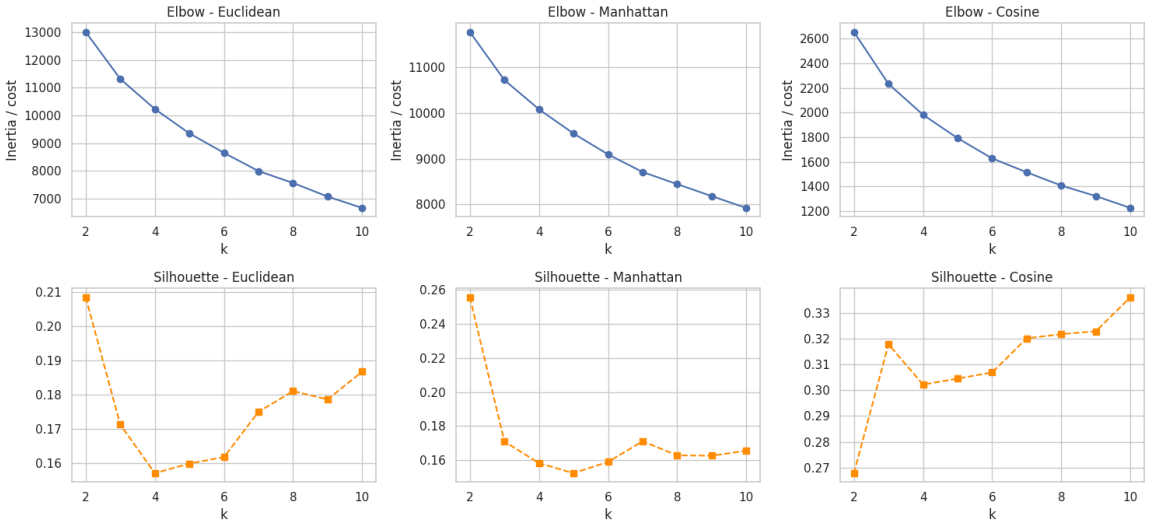


- *Gambar 3: Grid clustering Moons (kontrol).*

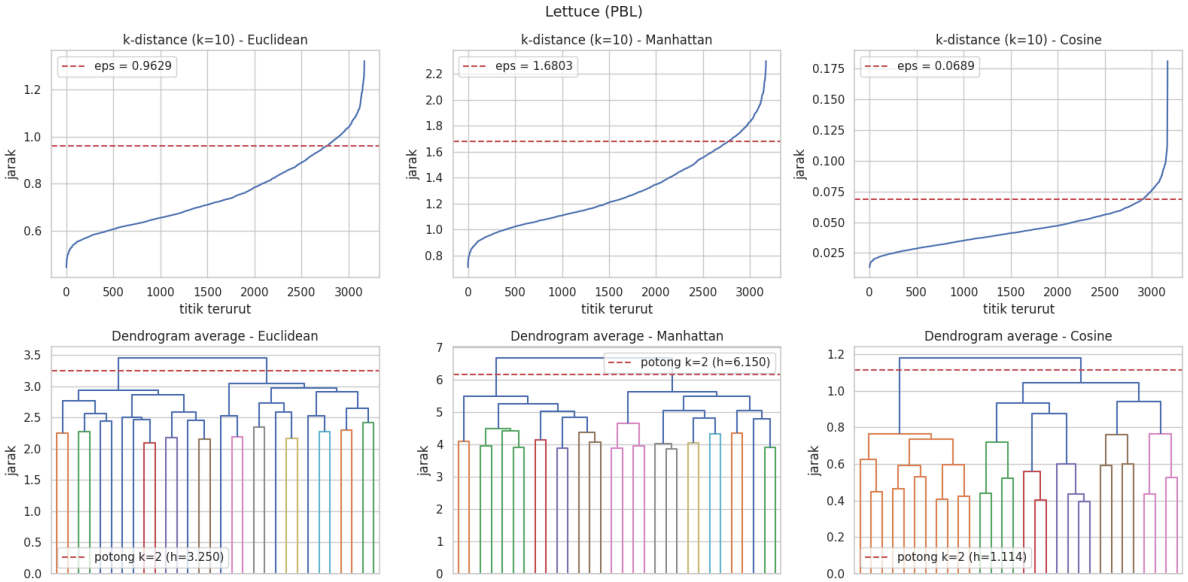


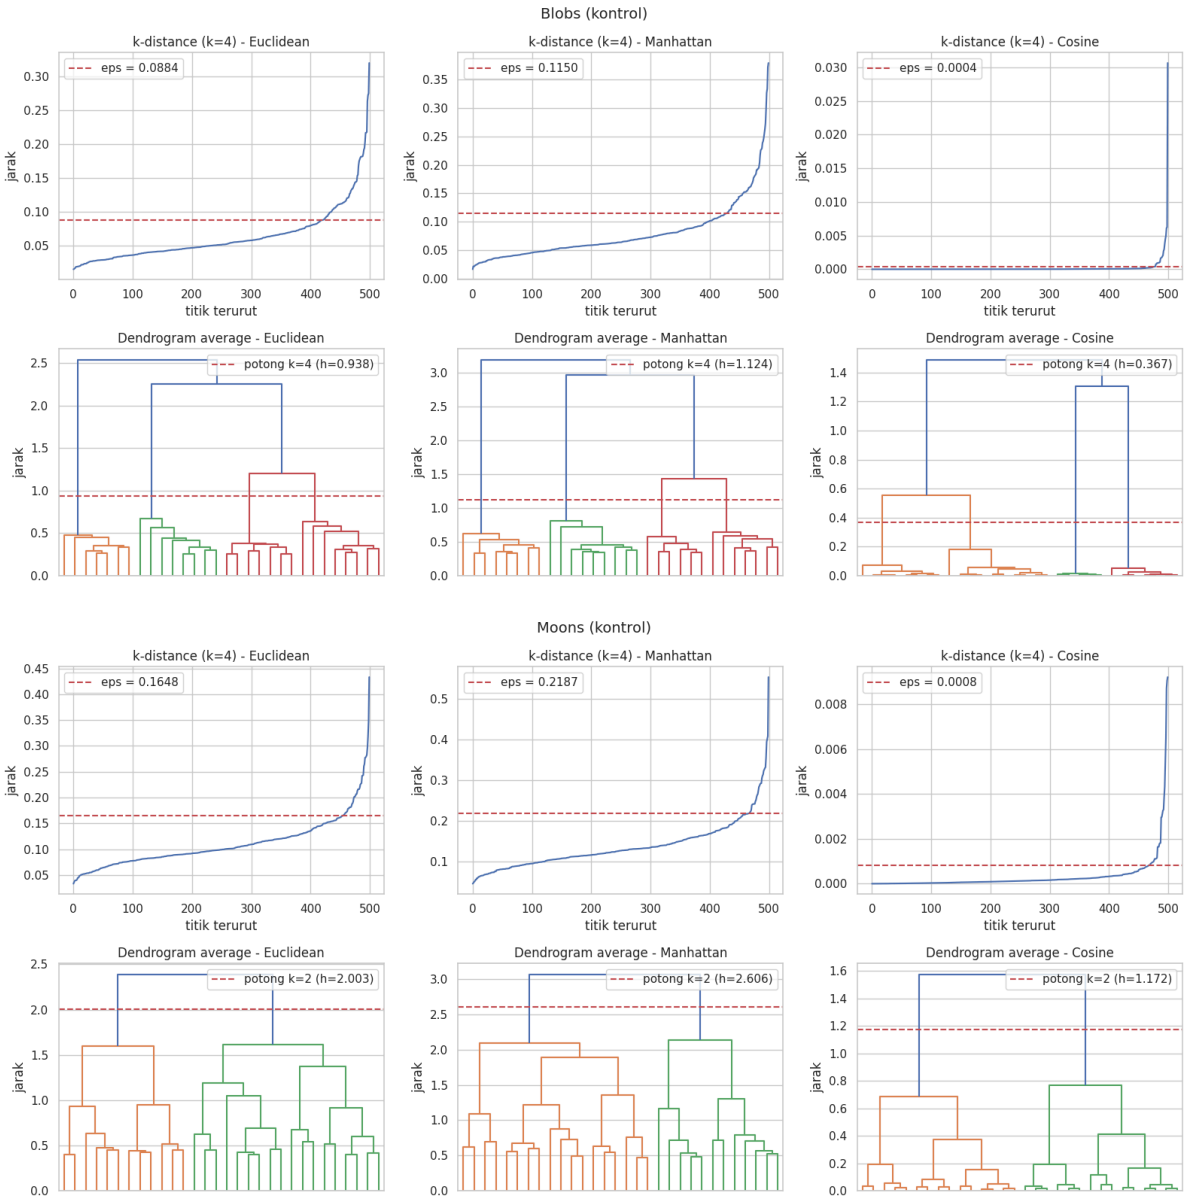
- *Gambar 2: Grid clustering Blobs (kontrol).*

5.3 Grafik Penyetelan Parameter



- *Gambar 4: Elbow dan Silhouette untuk pemilihan k (Lettuce).*





- Gambar 5–7: k-distance plot DBSCAN (eps ditandai) dan dendrogram dengan garis potong, untuk Lettuce, Blobs, Moons.

6. Pembahasan (± 1 halaman)

6.1 Pengujian Hipotesis

Kode	Status	Bukti dari hasil (rujuk tabel/gambar)
H1	Campuran	Blobs: K-Means–Euclidean memberi ARI = 1,0000 dan Silhouette 0,7979 (Tabel 2), tetapi Hierarchical dan K-Means Manhattan/Cosine juga ARI 1,0000; Euclidean tidak unik terbaik (Silhouette Cosine 0,9699 lebih tinggi). Didukung untuk ARI, tidak untuk "terbaik sendiri".
H2	Campuran	Moons (Tabel 3): DBSCAN Euclidean ARI 0,9293 dan Manhattan 0,9525, jauh di atas K-Means (0,4451 dan 0,4292).

Kode	Status	Bukti dari hasil (rujuk tabel/gambar)
		Namun DBSCAN Cosine gagal (13 cluster, ARI 0,1700), sehingga "apa pun metrik" tidak terpenuhi.
H3	Campuran	Dimensi rendah: pada Moons, DBSCAN Cosine merusak struktur (ARI 0,1700 vs 0,9293 Euclidean) — didukung. Pada Blobs Cosine justru baik (ARI 0,9470) karena cluster terpisah secara sudut. Bagian data berdimensi tinggi (TF-IDF/embedding) tidak dapat diuji; pada selada (5 dimensi) Cosine memberi Silhouette tertinggi (0,2931).
H4	Didukung (parsial)	Moons: rentang ARI Hierarchical antar metrik 0,2677 (0,4239–0,6916) vs K-Means 0,0159 (0,4292–0,4451). Pada Blobs keduanya identik antar metrik, dan pada selada rentang Silhouette Hierarchical (0,0846) hanya sedikit di atas K-Means (0,0634). DBSCAN tetap paling sensitif.
H5	Campuran	Selada: K-Medians (Manhattan) menaikkan Silhouette K-Means (0,2558 vs 0,2085) dan Hierarchical Manhattan stabil (0,2554), tetapi DBSCAN Manhattan turun tajam (0,1004). Manhattan tidak stabil di semua algoritma.

6.2 Analisis Algoritma dan Metrik

- Centroid adalah rata-rata anggota, yaitu titik yang meminimalkan jumlah kuadrat jarak Euclidean. Karena itu K-Means murni terikat pada Euclidean; Manhattan (K-Medians) dan Cosine (spherical) mengubah algoritma sekaligus metrik.
- Pada selada, ketiga pendekatan memberi Silhouette serupa pada metrik yang sama (Euclidean 0,2085; Cosine 0,2679–0,2931), menandakan data tidak membentuk cluster tegas sehingga pilihan algoritma kurang berpengaruh dibanding metrik. DBSCAN hanya menandai 0,3–0,9% titik sebagai noise; cophenetic correlation Hierarchical pada selada rendah (0,5259–0,5395) dibanding Blobs (0,8885–0,9430), yang menguatkan lemahnya struktur hierarki. Pada kontrol, K-Means cocok untuk Blobs bulat, sedangkan DBSCAN unggul pada Moons non-konveks tetapi sensitif terhadap eps (Blobs terpecah menjadi 7 cluster dengan 9% noise).
- DBSCAN paling sensitif terhadap pergantian metrik (ARI Moons 0,1700–0,9525; Silhouette selada 0,1004–0,2926), karena eps terkait skala jarak tiap metrik. Hierarchical menyusul, K-Means paling stabil karena terikat pada centroid.
- Sebagian konsisten: Cosine unggul pada Silhouette di selada dan Blobs, tetapi pada Moons hanya Silhouette K-Means/Hierarchical yang tinggi (0,71) sementara ARI-nya rendah. Silhouette tinggi tidak menjamin kecocokan dengan struktur sebenarnya, dan pada selada tidak ada label untuk memverifikasinya.

6.3 Keterbatasan

- Hasil DBSCAN sangat bergantung pada eps dan min_samples; pemilihan eps dari k-distance plot bersifat subjektif.
- K-Medians dan spherical k-means mencampur efek algoritma dan metrik sehingga pengaruh metrik tidak murni.
- DBI dihitung dengan Euclidean sehingga menguntungkan konfigurasi Euclidean; data PBL berukuran terbatas dan tanpa label.

7. Kesimpulan dan Rekomendasi (± ½ halaman)

7.1 Kesimpulan

Untuk data selada, konfigurasi terbaik adalah Hierarchical–Cosine (Silhouette 0,2931, DBI 1,9598), nyaris sama dengan DBSCAN–Cosine (0,2926; noise 0,3%). Spherical K-Means–Cosine tercepat (28,6 ms) tetapi DBI tertinggi (2,2656). Semua Silhouette di bawah 0,3, sehingga struktur cluster pada data selada lemah. Tujuan 2.2 terjawab: metrik berpengaruh nyata, terutama pada DBSCAN.

7.2 Rekomendasi Praktis

Gunakan K-Means–Euclidean untuk cluster bulat dan kompak; DBSCAN (Euclidean atau Manhattan) untuk bentuk non-konveks dengan eps disetel per metrik; Hierarchical–Cosine bila arah vektor lebih penting daripada besarnya dan data kecil (waktu 433,6 ms); hindari DBSCAN–Cosine pada data berdimensi rendah tanpa penyetelan eps.

7.3 Kartu Rekap untuk Perbandingan Lintas Tim (wajib)

Tim	Domain PBL	Dimensi / n	Konfigurasi terbaik	Metrik paling berpengaruh	Temuan utama (1 kalimat)
Kelompok 5	Agrikultur (estimasi waktu panen selada)	5 fitur / 3.169	Hierarchical–Cosine (average, k = 2)	Cosine (DBSCAN paling sensitif terhadap metrik)	Cosine memberi Silhouette tertinggi (0,2931), tetapi struktur cluster selada lemah (semua < 0,3).

8. Lampiran

- Kode program lengkap: https://colab.research.google.com/drive/1tIaB2wyomCLrV9O0Iub-DlYDcrNCdpxh?usp=sharing
- Tabel parameter final:

Algoritma	Metrik	Parameter final
K-Means / K-Medians / spherical	Euclidean / Manhattan / Cosine	Lettuce k = 2; Blobs k = 4; Moons k = 2; random_state = 42
DBSCAN	Euclidean / Manhattan / Cosine	Lettuce: eps 0,9629 / 1,6803 / 0,0689, min_samples = 10; Blobs: 0,0884 / 0,1150 / 0,0004, min_samples = 4; Moons: 0,1648 / 0,2187 / 0,0008, min_samples = 4 (urutan Euclidean / Manhattan / Cosine)
Hierarchical	Euclidean / Manhattan / Cosine	linkage = average; n_clusters: Lettuce 2, Blobs 4, Moons 2