LAPORAN HASIL KOMPARATIF METODE KLASIFIKASI

Pembelajaran Mesin

Prediksi Tahap Pertumbuhan Selada Hidroponik dengan Naive Bayes, SVM, KNN, dan XGBoost

Gaussian Naive Bayes · SVM (RBF) · K-Nearest Neighbors · XGBoost — terintegrasi dengan dataset proyek PBL kelompok

1. Identitas Laporan

Komponen	Isi
Judul	Eksperimen Komparasi Metode Klasifikasi (Naive Bayes, SVM, KNN, dan XGBoost) untuk Memprediksi Tahap Pertumbuhan Selada pada Aplikasi Prediksi Estimasi Waktu Panen
Kelompok	Kelompok 5
Mata kuliah / kelas	Pembelajaran Mesin / TI 3G / Teknik Informatika

Nama	NIM	Peran dalam eksperimen
Dina Kumala Sari	244107020072	- XGBoost
Muhammad Pearl Ochada	244107020064	- KNN
M. Yahya Irvansyah	244107020032	- Naive Bayes
Anselmus Marcel Putra Andria	244107020141	- Visualisasi
Sharren Elvaretta Pratamadya Fianto	244107020191	- SVM

2. Pendahuluan

2.1 Latar Belakang Topik PBL

Proyek PBL Kelompok 5 mengembangkan aplikasi mobile (Flutter + Flask REST API) untuk memprediksi estimasi waktu panen tanaman selada hidroponik dari data lingkungan, yaitu suhu, kelembapan, TDS, dan pH. Agar estimasi tersebut dapat dihitung, sistem perlu mengetahui pada tahap pertumbuhan mana sebuah tanaman berada. Oleh karena itu, permasalahan dirumuskan sebagai **klasifikasi tiga kelas**: tahap **Awal**, **Tengah**, dan **Akhir** pertumbuhan, yang diprediksi dari kondisi lingkungan pada hari pengukuran.

Banyak algoritma klasifikasi dapat dipakai untuk tugas ini, tetapi masing-masing membuat asumsi yang berbeda tentang data: Naive Bayes mengasumsikan fitur independen dan berdistribusi normal, SVM dan KNN bekerja berdasarkan jarak/kernel pada ruang fitur, sedangkan XGBoost membangun ansambel pohon keputusan yang mampu menangkap interaksi non-linear. Eksperimen ini membandingkan keempatnya dengan **protokol yang identik** (fitur, split, praproses, validasi silang, dan metrik yang sama) sehingga perbedaan hasil benar-benar dapat dikaitkan dengan karakter algoritmanya, bukan dengan perbedaan perlakuan.

2.2 Tujuan Eksperimen

- Membandingkan kinerja empat metode klasifikasi (Gaussian Naive Bayes, SVM kernel RBF, KNN, dan XGBoost) dalam memprediksi tahap pertumbuhan selada dari empat variabel lingkungan.

- Menilai pengaruh penyetelan hiperparameter (tuning) terhadap tiap metode dibandingkan konfigurasi bawaan.
- Menentukan metode terbaik berdasarkan kinerja pada data uji (tanaman yang tidak pernah dilihat saat pelatihan), stabilitas validasi silang, dan biaya komputasi, serta menjelaskan faktor yang menyebabkan perbedaan tersebut.

2.3 Hipotesis (Prediksi Awal)

Kode	Pernyataan hipotesis
H1	XGBoost memberikan F1 macro tertinggi pada data uji karena mampu menangkap hubungan non-linear dan interaksi antar-fitur lingkungan.
H2	Naive Bayes memberikan kinerja terendah karena asumsi distribusi normal per kelas dan independensi antar-fitur tidak sepenuhnya cocok dengan data sensor.
H3	Penyetelan hiperparameter meningkatkan F1 pada model yang sensitif terhadap hiperparameter (SVM, KNN, XGBoost) dan tidak berpengaruh pada Naive Bayes yang hanya memiliki satu hiperparameter minor.
H4	SVM (RBF) dan KNN, setelah standardisasi fitur, berada di antara Naive Bayes dan XGBoost, serta seluruh model melampaui baseline kelas mayoritas.
H5	Naive Bayes dan KNN lebih cepat dilatih/dituning dibanding SVM, sedangkan SVM paling mahal secara komputasi karena pencarian C dan gamma.

2.4 Karakteristik Data

Karakteristik	Isi
Sumber data & cara pengumpulan	Dataset Kaggle "Lettuce Growth Days" (jurijsruko/lettuce); pengukuran harian per tanaman dari sensor lingkungan pada budidaya hidroponik.
Jumlah sampel (baris)	Latih: 2.213 baris dari 49 tanaman. Uji: 956 baris dari 21 tanaman. Total 3.169 baris dari 70 tanaman.
Jumlah fitur (dimensi)	4 fitur numerik: Temperature (°C), Humidity (%), TDS Value (ppm), pH Level. Growth Days dipakai hanya untuk membentuk target, bukan sebagai fitur.
Tipe fitur	Seluruhnya numerik; tidak ada fitur kategorikal atau teks.
Target (label)	Tahap pertumbuhan 3 kelas (Awal / Tengah / Akhir) dari kuantil Growth Days data latih: Awal ≤ 16 hari, Tengah 16–31 hari, Akhir > 31 hari.
Sebaran kelas	Latih: Awal 784, Tengah 735, Akhir 694. Uji: Awal 336, Tengah 315, Akhir 305. Relatif seimbang; baseline kelas mayoritas pada data uji = 0,3515.
Missing value & duplikat	Tidak ada missing value pada fitur dan tidak ada baris duplikat pada data latih.

3. Dasar Teori Singkat

3.1 Metode Klasifikasi yang Dibandingkan

Metode	Prinsip kerja	Hiperparameter yang dituning	Kelebihan / kelemahan
Gaussian Naive Bayes	Menerapkan teorema Bayes dengan asumsi fitur saling independen; tiap fitur numerik dimodelkan sebagai distribusi normal per kelas, lalu kelas dipilih dari posterior tertinggi.	var_smoothing (penstabil varians).	Sangat cepat dan sederhana; lemah bila distribusi per kelas tidak normal atau saling tumpang tindih.

Metode	Prinsip kerja	Hiperparameter yang dituning	Kelebihan / kelemahan
SVM (kernel RBF)	Mencari hyperplane dengan margin maksimum pada ruang fitur hasil kernel RBF sehingga batas kelas non-linear dapat dipelajari.	C (penalti kesalahan), gamma (lebar kernel).	Kuat pada batas non-linear; sensitif skala fitur dan mahal saat tuning.
KNN	Memprediksi kelas dari mayoritas k tetangga terdekat; non-parametrik dan tanpa fase pelatihan eksplisit.	n_neighbors, weights, metric (Euclidean/Manhattan).	Intuitif; sensitif skala, nilai k, dan fitur yang kurang informatif.
XGBoost	Gradient boosting dari banyak pohon keputusan dangkal; tiap pohon baru memperbaiki kesalahan ansambel sebelumnya.	n_estimators, max_depth, learning_rate.	Menangkap interaksi non-linear dan tahan skala fitur; banyak hiperparameter dan risiko overfitting bila tidak dituning.

3.2 Metrik Evaluasi

Metrik	Definisi	Catatan penggunaan
Akurasi	Proporsi prediksi benar terhadap seluruh data uji.	Dibandingkan dengan baseline kelas mayoritas (0,3515).
Precision (macro)	Rata-rata tanpa bobot dari TP/(TP+FP) tiap kelas.	Menunjukkan seberapa dapat dipercaya prediksi suatu kelas.
Recall (macro)	Rata-rata tanpa bobot dari TP/(TP+FN) tiap kelas.	Menunjukkan seberapa banyak data suatu kelas yang berhasil ditemukan.
F1 (macro)	Rata-rata harmonik precision dan recall, dirata-ratakan antar kelas.	Metrik utama pemeringkatan; memperlakukan setiap kelas setara.
ROC-AUC (OvR)	Luas area di bawah kurva ROC, satu kelas lawan sisanya, dirata-ratakan (macro).	Menilai kualitas peringkat probabilitas, bebas dari ambang keputusan.
Waktu tuning / prediksi	Durasi GridSearchCV (detik) dan durasi prediksi data uji (milidetik).	Indikator biaya komputasi.

3.3 Rujukan Jurnal

Jurnal	Relevansi untuk eksperimen ini
Lauguico et al. (2020), Comparative Analysis of Machine Learning Algorithms for Lettuce Growth Stage Classification, IJESD 11(9)	Membandingkan LR, KNN, dan Linear SVM untuk tiga tahap pertumbuhan selada dengan fitur terstandardisasi, validasi silang, dan tuning; KNN terbaik (CV mean accuracy 87,06%, akurasi uji sekitar 91%). Alur standardisasi → CV → tuning → metrik ditiru pada eksperimen ini.
AlBroomi et al. (2026), ML-Based Prediction of Lettuce Growth Utilising Online Environmental Datasets, J. Phys.: Conf. Ser. 3191	Menyebut SVM, KNN, Gaussian NB, dan XGBoost lazim dipakai untuk prediksi pertumbuhan selada; menekankan pembersihan data, normalisasi, dan bahwa tuning hiperparameter meningkatkan model boosting secara nyata.
Rizkiana et al. (2021), Plant growth prediction model for lettuce using ANN, IOP EES 733	Memakai empat variabel lingkungan sebagai input dan normalisasi data; mendukung pemilihan suhu, kelembapan, TDS, dan pH sebagai prediktor.

3.4 Prinsip Apple-to-Apple

- **Fitur sama:** empat fitur lingkungan untuk semua model.

- **Split sama:** pemisahan latih/uji berdasarkan Plant_ID; kuantil kelas dihitung hanya dari data latih.
- **Pipeline sama:** imputasi median → StandardScaler → model.
- **Validasi dan tuning sama:** StratifiedGroupKFold 5-lipat (grup = Plant_ID), GridSearchCV dengan skor F1 macro, random_state = 42.

4. Metodologi

4.1 Dataset dan Pembagian Data

Data latih berasal dari file lettuce_dataset_training.csv (tanpa header, sehingga nama kolom diberikan manual), sedangkan data uji adalah tanaman pada file penuh lettuce_dataset_updated.csv yang **tidak** ada di file latih. Pemisahan dilakukan **per tanaman (Plant_ID)**, bukan per baris. Alasannya, pengukuran harian dari tanaman yang sama sangat berkorelasi; jika hari-hari berurutan satu tanaman tersebar di data latih dan uji, model akan "mengenali" tanaman tersebut dan skor menjadi terlalu optimistis (kebocoran data). Dengan split per tanaman, skor uji mencerminkan kemampuan generalisasi ke tanaman baru, yang sesuai dengan skenario penggunaan aplikasi.

4.2 Pembentukan Target Kelas

Kolom Growth Days dibagi menjadi tiga kelas berdasarkan kuantil 1/3 dan 2/3 data latih (16 dan 31 hari), sehingga kelas relatif seimbang. Batas yang sama diterapkan pada data uji agar tidak ada informasi data uji yang bocor ke proses pelatihan. Growth Days tidak dipakai sebagai fitur karena merupakan sumber langsung dari target.

4.3 Praproses

- Imputasi median (SimpleImputer) disiapkan untuk berjaga-jaga; pada data ini tidak ada missing value sehingga tidak mengubah data.
- StandardScaler diterapkan di dalam pipeline sehingga rata-rata dan simpangan baku hanya dihitung dari data latih tiap lipatan (tanpa kebocoran). Standardisasi penting bagi SVM dan KNN yang berbasis jarak; Naive Bayes dan XGBoost tidak bergantung padanya, tetapi tetap diberi perlakuan sama demi kesetaraan.
- Outlier tidak dihapus agar sifat asli data sensor tetap terbaca.

4.4 Validasi Silang dan Penyetelan Hiperparameter

Seluruh model dievaluasi dengan StratifiedGroupKFold 5-lipat (shuffle, grup = Plant_ID) sehingga satu tanaman tidak pernah muncul di lipatan latih dan validasi sekaligus. Kinerja bawaan diukur dengan cross_val_score, kemudian hiperparameter dicari dengan GridSearchCV (skor F1 macro, refit pada seluruh data latih).

Model	Grid hiperparameter	Jumlah kombinasi
Naive Bayes	var_smoothing: 10^{-11} s.d. 10^{-5} (7 nilai, skala log)	7
SVM (RBF)	C: 0,1; 1; 10; 100 × gamma: scale; 0,01; 0,1; 1	16
KNN	n_neighbors: 3, 5, 11, 21, 31 × weights: uniform/distance × metric: euclidean/manhattan	20
XGBoost	n_estimators: 100, 300 × max_depth: 3, 5 × learning_rate: 0,05; 0,1	8

4.5 Evaluasi pada Data Uji

Model terbaik tiap algoritma (best_estimator_) dievaluasi sekali pada data uji menggunakan metrik pada Bagian 3.2. Pemeringkatan memakai **F1 macro** karena memperlakukan ketiga kelas setara. Hasil juga dibandingkan dengan baseline akurasi kelas mayoritas (0,3515) untuk memastikan model benar-benar belajar. Interpretasi tambahan dilakukan dengan confusion matrix ternormalisasi, laporan per kelas, dan permutation importance pada model terbaik.

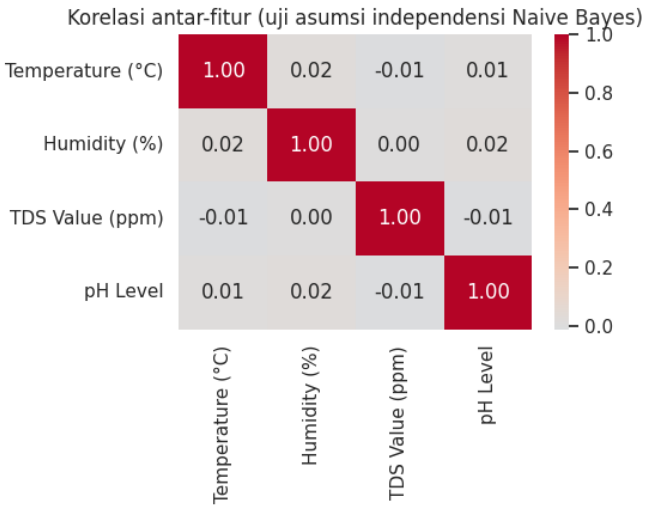
4.6 Reproducibility

- random_state = 42 untuk seluruh proses acak (split CV, SVM, XGBoost).
- Pustaka: scikit-learn 1.6.1 dan xgboost 3.4.1, bersama numpy, pandas, matplotlib, dan seaborn.
- Notebook: klasifikasi_perbandingan_selada.ipynb; hasil tabel disimpan sebagai perbandingan_klasifikasi.csv.

5. Hasil

5.1 Uji Asumsi Independensi Fitur

Sebelum membandingkan model, korelasi antar-fitur pada data latih diperiksa karena Naive Bayes mengasumsikan independensi. Gambar 1 menunjukkan seluruh korelasi antar-fitur mendekati nol (rentang −0,01 sampai 0,02), sehingga asumsi independensi **terpenuhi** pada data ini.



Gambar 1. Korelasi antar-fitur pada data latih

5.2 Dampak Penyetelan Hiperparameter

Tabel 1. F1 macro validasi silang: konfigurasi bawaan vs setelah tuning, beserta parameter terbaik

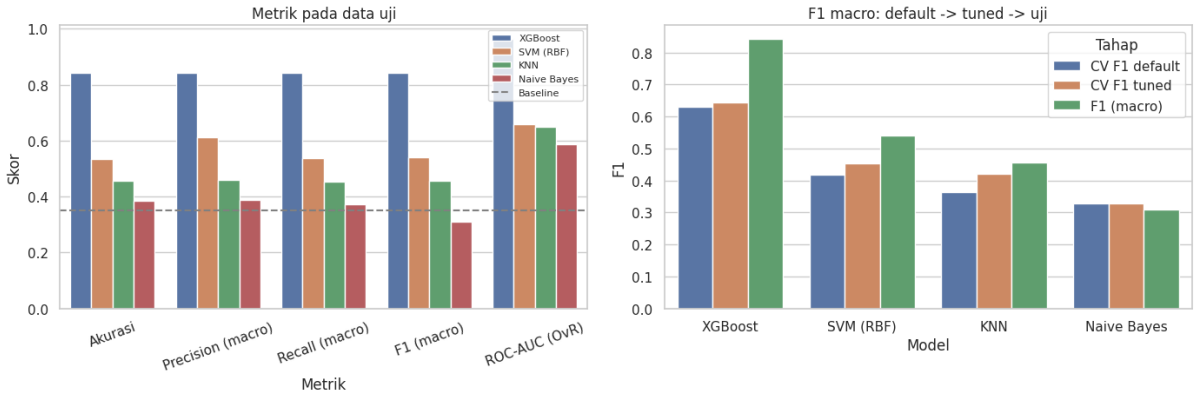
Model	CV F1 bawaan	CV F1 tuning	Selisih	Parameter terbaik
XGBoost	0,6297	0,6432	+0,0135	learning_rate = 0,1; max_depth = 5; n_estimators = 300
SVM (RBF)	0,4182	0,4521	+0,0339	C = 100; gamma = 0,1
KNN	0,3634	0,4196	+0,0562	metric = manhattan; n_neighbors = 11; weights = distance
Naive Bayes	0,3292	0,3292	0,0000	var_smoothing = 1e-11

5.3 Tabel Ringkasan Hasil pada Data Uji

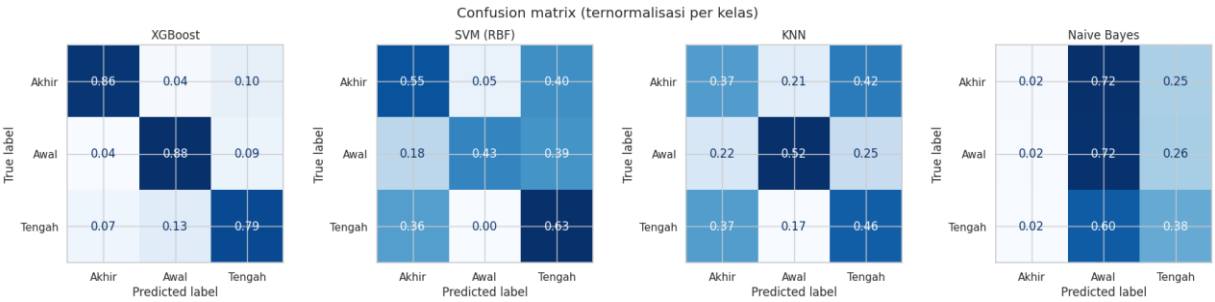
Tabel 2. Kinerja pada data uji (956 baris, 21 tanaman; baseline akurasi = 0,3515)

Rank	Model	Akurasi	Precision (macro)	Recall (macro)	F1 (macro)	ROC-AUC (OvR)	Waktu tuning / prediksi
1	XGBoost	0,8431	0,8437	0,8425	0,8429	0,9643	7,37 s / 22,68 ms
2	SVM (RBF)	0,5356	0,6121	0,5381	0,5402	0,6586	110,64 s / 97,48 ms
3	KNN	0,4550	0,4601	0,4526	0,4549	0,6491	2,58 s / 18,27 ms
4	Naive Bayes	0,3849	0,3864	0,3737	0,3104	0,5866	5,68 s / 3,82 ms

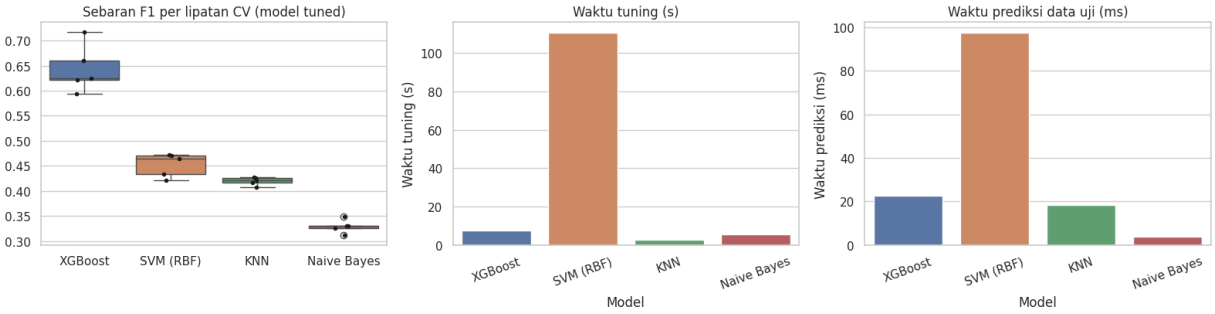
5.4 Visualisasi Hasil



Gambar 2. Perbandingan metrik pada data uji (kiri) dan F1 macro bawaan → tuning → uji (kanan)



Gambar 3. Confusion matrix ternormalisasi per kelas untuk keempat model



Gambar 4. Sebaran F1 per lipatan CV (kiri), waktu tuning (tengah), dan waktu prediksi (kanan)

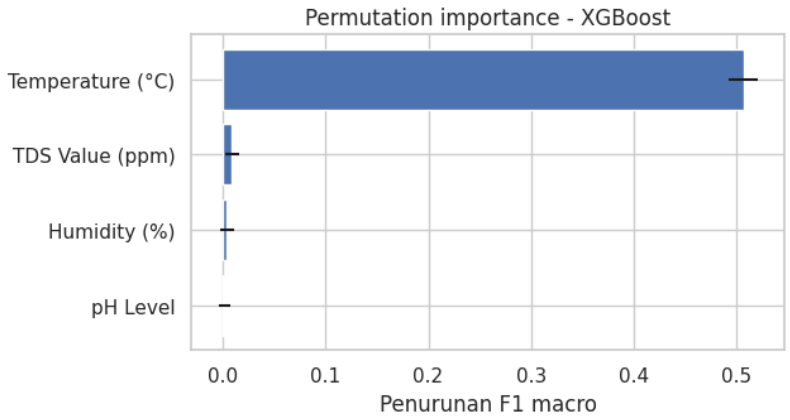
5.5 Laporan per Kelas

Tabel 3. Precision / recall / F1 per kelas pada data uji

Model	Kelas	Precision	Recall	F1	Support
XGBoost	Awal	0,8429	0,8780	0,8601	336
	Tengah	0,8065	0,7937	0,8000	315
	Akhir	0,8818	0,8557	0,8686	305
SVM (RBF)	Awal	0,9057	0,4286	0,5818	336
	Tengah	0,4396	0,6349	0,5195	315
	Akhir	0,4912	0,5508	0,5193	305
KNN	Awal	0,6027	0,5238	0,5605	336
	Tengah	0,4050	0,4603	0,4309	315
	Akhir	0,3725	0,3738	0,3732	305
Naive Bayes	Awal	0,3696	0,7173	0,4879	336
	Tengah	0,4211	0,3810	0,4000	315
	Akhir	0,3684	0,0230	0,0432	305

5.6 Faktor Paling Berpengaruh pada Model Terbaik

Permutation importance pada XGBoost (diukur dari penurunan F1 macro saat satu fitur diacak, 20 pengulangan) menunjukkan **Temperature (°C)** sangat dominan dengan penurunan sekitar 0,51. TDS Value, Humidity, dan pH Level hampir tidak memberi kontribusi (mendekati nol).



Gambar 5. Permutation importance model XGBoost pada data uji

6. Pembahasan

6.1 Pengujian Hipotesis

Kode	Status	Bukti dari hasil
H1	Didukung kuat	XGBoost unggul pada semua metrik: F1 macro 0,8429 dan akurasi 0,8431 (Tabel 2), selisih F1 dengan peringkat 2 (SVM) sebesar 0,3027. ROC-AUC 0,9643 juga tertinggi.
H2	Sebagian didukung	Naive Bayes memang terendah (F1 0,3104; akurasi 0,3849, hanya 0,0334 di atas baseline). Namun alasannya bukan pelanggaran independensi: korelasi antar-fitur ≈ 0 (Gambar 1). Penyebab yang lebih mungkin adalah asumsi distribusi normal per kelas yang tidak cocok, sehingga kelas yang tumpang tindih tidak terpisahkan.

Kode	Status	Bukti dari hasil
H3	Sebagian didukung	Tuning menaikkan CV F1 pada KNN (+0,0562), SVM (+0,0339), dan XGBoost (+0,0135); Naive Bayes tidak berubah (Tabel 1). Kenaikan terbesar terjadi pada KNN, bukan pada XGBoost seperti yang ditulis jurnal rujukan; XGBoost sudah kuat pada konfigurasi bawaan (0,6297).
H4	Sebagian didukung	Urutan SVM (0,5402) dan KNN (0,4549) di antara XGBoost dan Naive Bayes terpenuhi. Seluruh model melampaui baseline akurasi, tetapi Naive Bayes hanya tipis dan F1 macro-nya (0,3104) justru di bawah tingkat acak untuk tiga kelas (sekitar 0,33).
H5	Sebagian didukung	Tuning SVM paling lama (110,64 s) dan prediksinya paling lambat (97,48 ms). KNN tercepat dituning (2,58 s). Naive Bayes tercepat saat prediksi (3,82 ms), tetapi waktu tuningnya (5,68 s) justru lebih lama daripada KNN.

6.2 Analisis per Metode

- **XGBoost.** Kinerja jauh di atas model lain menandakan hubungan antara kondisi lingkungan dan tahap pertumbuhan bersifat non-linear dan tidak dapat dipisahkan oleh batas sederhana. Pohon keputusan dapat membuat banyak aturan bertingkat pada satu fitur (misalnya rentang suhu tertentu), sesuai dengan temuan permutation importance bahwa suhu menjadi penentu utama (Gambar 5). Pada model ini, precision dan recall seimbang pada ketiga kelas (F1 0,80–0,87).
- **SVM (RBF).** Berada di peringkat kedua tetapi pola kesalahannya timpang: kelas Awal memiliki precision tinggi (0,9057) namun recall rendah (0,4286). Artinya SVM berhati-hati memprediksi Awal, tetapi banyak data Awal terlewat dan masuk ke kelas lain. Nilai C terbaik (100) berada di batas atas grid, sehingga kemungkinan kinerjanya masih dapat naik bila grid diperluas.
- **KNN.** Hasil sedang (F1 0,4549). Karena hanya empat fitur dan satu fitur (suhu) yang benar-benar informatif, tiga fitur lain menambah "derau" pada perhitungan jarak sehingga tetangga terdekat sering berasal dari kelas yang salah. Metrik Manhattan dan pembobotan jarak dipilih tuning, konsisten dengan fungsi jarak yang lebih tahan terhadap fitur berderau.
- **Naive Bayes.** Kelas Akhir hampir tidak pernah diprediksi (recall 0,0230; F1 0,0432) dan model condong ke kelas Awal (recall 0,7173). Karena fitur independen, kegagalan berasal dari model Gaussian per kelas: bila distribusi fitur antar kelas saling tumpang tindih atau tidak berbentuk lonceng, posterior tidak dapat membedakan kelas, terutama kelas Akhir. var_smoothing terbaik berada di batas bawah grid dan tidak mengubah hasil.

6.3 Analisis Kesalahan per Kelas

Pada XGBoost, kelas **Tengah** adalah yang tersulit (F1 0,8000) dibanding Awal (0,8601) dan Akhir (0,8686). Hal ini wajar karena kelas Tengah berbatasan dengan dua kelas lain sehingga data di dekat batas 16 hari dan 31 hari mudah tertukar; kelas Awal dan Akhir hanya berbatasan dengan satu kelas. Pola serupa tampak pada SVM dan KNN, yang kinerjanya pada kelas Tengah dan Akhir lebih rendah daripada Awal. Batas kelas dibentuk dari kuantil, sehingga hari yang berdekatan di sisi batas yang berbeda memang bernilai hampir sama secara biologis, dan sebagian kesalahan bersifat tak terhindarkan.

6.4 Konsistensi Validasi Silang dan Data Uji

F1 pada data uji (XGBoost 0,8429; SVM 0,5402; KNN 0,4549) lebih tinggi daripada CV F1 setelah tuning (0,6432; 0,4521; 0,4196), sedangkan Naive Bayes sedikit lebih rendah (0,3104 vs 0,3292). Beberapa penjelasan yang mungkin: model akhir dilatih dari seluruh 49 tanaman (lebih banyak daripada sekitar

39 tanaman per lipatan CV), dan 21 tanaman uji kebetulan lebih "mudah" atau lebih mirip data latih. Sebaran F1 antar-lipatan XGBoost cukup lebar (kira-kira 0,59–0,72; Gambar 4) sehingga angka uji 0,84 yang berada di atas seluruh lipatan perlu dibaca hati-hati. Meski demikian, **urutan peringkat model konsisten** pada CV maupun data uji, dan sebaran XGBoost tetap terpisah jelas dari model lain, sehingga kesimpulan bahwa XGBoost terbaik tidak bergantung pada satu pembagian data saja.

6.5 Biaya Komputasi

XGBoost memberi kinerja terbaik dengan biaya yang wajar: tuning 7,37 s dan prediksi 22,68 ms untuk 956 baris. SVM adalah yang paling mahal (tuning 110,64 s, prediksi 97,48 ms) padahal kinerjanya jauh lebih rendah, sebagian karena pengaturan probability = True yang menambah proses kalibrasi dan karena grid 16 kombinasi dengan nilai C besar. Naive Bayes tercepat saat prediksi (3,82 ms) tetapi akurasinya tidak memadai, sehingga keunggulan kecepatan tidak relevan untuk tujuan aplikasi ini. Untuk aplikasi mobile dengan Flask API, waktu prediksi XGBoost masih jauh di bawah batas yang terasa oleh pengguna.

6.6 Keterbatasan

- Jumlah tanaman terbatas (49 latih, 21 uji) dan evaluasi uji hanya memakai satu pembagian; belum ada pengulangan split atau uji signifikansi statistik, sehingga selisih kecil antar-model (terutama KNN vs SVM) perlu dibaca hati-hati. Selisih XGBoost terhadap model lain sangat besar sehingga kesimpulannya kuat.
- Dominasi suhu pada permutation importance kemungkinan terkait tren suhu terhadap hari pertumbuhan pada data ini (dugaan, belum diuji). Bila benar, model belajar pola waktu melalui suhu, dan kinerjanya dapat berbeda pada kondisi budidaya lain.
- Batas kelas dibentuk dari kuantil sehingga bersifat sewenang-wenang; hasil dapat berubah bila kelas didefinisikan berdasarkan fase biologis tanaman.
- Grid hiperparameter terbatas; beberapa parameter terbaik berada di tepi grid (C SVM; learning_rate, max_depth, dan n_estimators XGBoost; var_smoothing Naive Bayes) sehingga optimum sebenarnya mungkin belum tercapai, dan ini dapat mempengaruhi seluruh model secara berbeda.
- Fitur terbatas pada empat variabel lingkungan; tidak ada fitur historis (misalnya rata-rata suhu beberapa hari sebelumnya).

7. Kesimpulan dan Rekomendasi

7.1 Kesimpulan

Pada klasifikasi tahap pertumbuhan selada (Awal/Tengah/Akhir) dari empat variabel lingkungan, **XGBoost adalah metode terbaik** dengan akurasi 0,8431, F1 macro 0,8429, dan ROC-AUC 0,9643, jauh melampaui SVM (F1 0,5402), KNN (0,4549), dan Naive Bayes (0,3104). Keunggulan ini konsisten pada validasi silang dan data uji, serta tidak diikuti biaya komputasi yang besar (tuning 7,37 s). Penyetelan hiperparameter paling bermanfaat bagi KNN dan SVM, sedangkan Naive Bayes tidak terbantu karena kegagalannya bersumber dari asumsi distribusi, bukan dari parameter. Faktor paling menentukan prediksi adalah suhu. Tujuan 2.2 terjawab: pemilihan metode klasifikasi berpengaruh besar terhadap kinerja pada data selada ini.

7.2 Rekomendasi Praktis

- Gunakan **XGBoost** (learning_rate 0,1; max_depth 5; n_estimators 300) sebagai model klasifikasi tahap pertumbuhan pada aplikasi PBL.
- Hindari Gaussian Naive Bayes untuk data ini; bila diperlukan model ringan, pertimbangkan alternatif lain daripada Naive Bayes.
- Perluas grid pada tuning lanjutan (C SVM lebih besar; n_estimators, max_depth, dan learning_rate XGBoost lebih bervariasi) dan ulangi evaluasi dengan beberapa split berbeda untuk memastikan kestabilan.
- Pertimbangkan penambahan fitur historis (rata-rata atau tren beberapa hari) dan pendefinisian kelas berdasarkan fase biologis agar model lebih bermakna secara agronomi.

7.3 Kartu Rekap untuk Perbandingan Lintas Tim

Tim	Domain PBL	Dimensi / n	Konfigurasi terbaik	Faktor paling berpengaruh	Temuan utama
Kelompok 5	Agrikultur (estimasi waktu panen selada)	4 fitur / 3.169 baris (70 tanaman)	XGBoost (lr 0,1; depth 5; 300 pohon)	Suhu (Temperature); hampir semua kontribusi	XGBoost mencapai F1 macro 0,8429, jauh di atas SVM (0,5402), KNN (0,4549), dan Naive Bayes (0,3104).

8. Daftar Pustaka dan Lampiran

- Lauguico, S. et al. (2020). Comparative Analysis of Machine Learning Algorithms for Lettuce Growth Stage Classification. International Journal of Emerging Science and Development (IJESD), 11(9).
- AlBroomi, et al. (2026). ML-Based Prediction of Lettuce Growth Utilising Online Environmental Datasets. Journal of Physics: Conference Series, 3191.
- Rizkiana, et al. (2021). Plant growth prediction model for lettuce using ANN. IOP Conference Series: Earth and Environmental Science, 733.

- Kode program lengkap: https://colab.research.google.com/drive/1BDd7sVp0KZsUwKBElN4rmWhEYAcm3H7_?usp=sharing

Tabel parameter final

Model	Parameter final	Catatan
Naive Bayes	var_smoothing = 1e-11	Di batas bawah grid
SVM (RBF)	C = 100; gamma = 0,1; probability = True	C di batas atas grid
KNN	n_neighbors = 11; weights = distance; metric = manhattan	Nilai di bagian dalam grid
XGBoost	n_estimators = 300; max_depth = 5; learning_rate = 0,1; objective = multi:softprob; tree_method = hist	Semua di batas atas grid
Umum	imputasi median → StandardScaler; StratifiedGroupKFold 5-lipat; skor F1 macro; random_state = 42	Pipeline identik untuk semua model